

Raport - 1

Jakub Gieźgała & Piotr Kupidura

12.05.2025

1 Wstęp

Celem projektu jest rozwinięcie i porównanie różnych wariantów sieci U-Net MICCAI 2015, 234–241 w celu segmentacji komórek w obrazach pochodzących z:

- mikroskopii fluorescencyjnej (*Fluo*),
- mikroskopii kontrastu fazowego (*Phc*),
- mikroskopii kontrastu interferencyjnego (*DIC*).

Modele będą trenowane na danych z pojedynczych eksperymentów oraz na zbiorze połączonym, nie tylko w celu poszukiwania optymalnych hiperparametrów, ale także najefektywniejszej funkcji kosztu, która docelowo będzie średnią ważoną metryk takimi jak *CrossEntropy*, *Dice coefficient* oraz *IoU*.

2 Model

2.1 Architektura U-Net

Bazą jest U-Net (2D) z czterema poziomami enkodera i dekodera oraz skip-connections. Wykorzystano:

- Filtry 3 x 3 z paddingiem `same` (padding=1),
- BatchNorm2d i funkcją aktywacji ReLU,
- Skip Connections między warstwami o różnych rozmiarach

2.2 Funkcje straty

Badane warianty:

- **Cross-Entropy Loss**,
- **Dice Loss**,
- **IoU loss** jako Jaccard Index

Dodatkowo testowana będzie kombinacja liniowa różnych funkcji kosztu z odpowiednimi wagami.

3 Postępy

Do tej pory zrealizowano następujące zadania:


- Przygotowanie skryptów do wczytywania i preprocessingu danych.
- Implementacja bazowego modelu 2D U-Net zgodnie z wymaganiami (SAME padding, skip-connections)
- Konwersja identyfikatorów komórek (instance IDs) na semantyczne maki.
- Weryfikacja, że rozmiary wyjść modelu są zgodne z rozmiarami wejść.

4 Plany dalszych prac


1. Wykorzystanie narzędzia `textbfClearML` do zarządzania wieloma powtórzeniami i skuteczne porównanie wyników wielu konfiguracji.
2. Przeprowadzenie **grid search** w celu doboru optymalnych hiperparametrów (learning rate, liczba warstw, wielkość batcha) na mniejszej liczbie epok, wykorzystując cały zestaw danych.
3. Implementacja architektury **BiFPN** opisanej tutaj z U-Net jako backbone (oraz przetestowanie innych możliwości) w celu poprawy fuzji wieloskalowych cech, co może poprawić predykcję modelu.
4. Testowanie kombinacji różnych funkcji kosztu.
5. Rozbudowa pipeline'u augmentacji danych (rotacje, jitter).

5 Podsumowanie


Dotychczasowe prace potwierdzają wstępną poprawność implementacji oraz przygotowania danych. Oczywiście dalej będziemy ulepszać istniejącą do tej pory implementację (uwzględnienie Xavier initialization). Integracja ClearML i grid search pozwoli na systematyczne porównanie wielu eksperymentów, a implementacja BiFPN może przynieść dodatkowy wzrost jakości segmentacji. Udało nam się już wykorzystać tę metodę na trudnym zbiorze danych **VOC2011** w problemie segmentacji dla wielu klas. To, z czym mamy problem, to rozpoznawanie dużych obiektów, będących na całym analizowanym obrazie, ale za pomocą polepszenia architektury, być może uda się rozwiązać ten problem. Wykorzystywaliśmy w tym celu **EfficientNet** oraz **ResNet50**, które także mogą być użyte jako backbone w przypadku trenowania modelu U-Net. Nasze postępy sukcesywnie będziemy zamieszczać w naszym repozytorium.



Rysunek 1: Przykładowa predykcja modelu



Rysunek 2: Ground truth



Rysunek 3: Oryginalne zdjęcie